

Algoritmos Genéticos en Espacios Métricos

De $\mathbb{R}^n$ a la Convergencia Débil

C. Fabián Beltrán I.

Matemáticas Aplicadas y Computación

03 de Junio

BLX- α y Mutación Gaussiana

Índice general

- 1 Introducción y Motivación
- 2 Operadores en Codificación Real
- 3 Modelado Estocástico
- 4 Límite de Campo Medio
- 5 Convergencia Débil
- 6 Esquema y Limitaciones
- 7 Comparación y Conclusión
- 8 Cierre

- **Problemas reales** tienen variables **continuas**
 - Pesos, coordenadas, parámetros físicos
 - Funciones, curvas, superficies
- **Codificación binaria:**
 - Requiere discretización $\rightarrow$ pérdida de precisión
 - Espacio de búsqueda finito pero enorme
- **Ventaja de la codificación real:**
 - Respeta la topología del espacio
 - Operadores naturales (mutación gaussiana)

Nota: La codificación real trabaja directamente con el valor de θ (el genotipo), sin una "codificación" en el sentido binario.

Espacio de búsqueda y su estructura

Espacio de genotipos

$$\mathcal{X} \subseteq \mathbb{R}^n \quad (\text{subconjunto acotado o todo } \mathbb{R}^n)$$

Espacio de poblaciones (con N individuos)

$$\mathcal{X}^N = \underbrace{\mathcal{X} \times \mathcal{X} \times \cdots \times \mathcal{X}}_{N \text{ veces}}$$

Distancia (métrica) para definir vecindad y convergencia

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2 = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Definición: Espacio Métrico

Un espacio métrico es una pareja (X, d) donde X es un conjunto y d es una función de distancia que satisface:

① **No negatividad y definida positiva:**

$$d(x, y) \geq 0 \quad \text{y} \quad d(x, y) = 0 \iff x = y$$

② **Simetría:**

$$d(x, y) = d(y, x)$$

③ **Desigualdad triangular:**

$$d(x, z) \leq d(x, y) + d(y, z)$$

Nota: Todo espacio normado es métrico (con $d(x, y) = \|x - y\|$), pero no todo espacio métrico es normado.

Operadores: Cruce BLX- α


Definición

Dados dos padres $\mathbf{p}, \mathbf{q} \in \mathbb{R}^n$, para cada coordenada i se define:

$$d_i = |p_i - q_i|$$

$$\text{intervalo} = [\min(p_i, q_i) - \alpha d_i, \max(p_i, q_i) + \alpha d_i]$$

Interpretación gráfica



- $\alpha \geq 0$ (típicamente $\alpha = 0.5$)
- Controla la exploración fuera del intervalo de los padres

Definición

Dado un individuo $\mathbf{y} \in \mathbb{R}^n$, el individuo mutado es:

$$\tilde{\mathbf{y}} = \mathbf{y} + \mathbf{z}$$

donde $\mathbf{z} = \sigma(\mathcal{N}_1(0, 1), \dots, \mathcal{N}_n(0, 1))$.

- σ : intensidad de mutación (parámetro de escala)
- $\mathcal{N}_i(0, 1)$: normales estándar independientes
- **Soporte completo** en $\mathbb{R}^n$ (puede alcanzar cualquier punto)

Nota: Por el principio de máxima entropía, para media y varianza fijas, la distribución normal es la que maximiza la entropía, lo que la hace ideal para una exploración no sesgada.

Modelado de la población: Medida empírica

Población en tiempo t

$$P_t = \{\mathbf{x}_1^{(t)}, \mathbf{x}_2^{(t)}, \dots, \mathbf{x}_N^{(t)}\} \subset \mathbb{R}^n$$

Medida empírica asociada

$$\mu_t^N = \frac{1}{N} \sum_{i=1}^N \delta_{\mathbf{x}_i^{(t)}}$$

donde $\delta_{\mathbf{x}}$ es la masa de Dirac en $\mathbf{x}$.

- μ_t^N es una **medida de probabilidad** sobre $\mathbb{R}^n$
- Describe la **distribución** de la población en el espacio
- $\mu_t^N(A) =$ proporción de individuos en $A \subseteq \mathbb{R}^n$
- Permite **comparar poblaciones** de diferente tamaño

Evolución como Kernel de Markov

Kernel de transición

El AG define un kernel K_N que actúa sobre medidas empíricas:

$$\mu_{t+1}^N = K_N(\mu_t^N)$$

Componentes del kernel K_N

- **Selección:** proporcional al fitness (ruleta, torneo)
- **Cruce:** BLX- α (extiende el intervalo entre padres)
- **Mutación:** Gaussiana $\mathbf{x}' = \mathbf{x} + \mathcal{N}(\mathbf{0}, \sigma^2 I)$

$$P_t \xrightarrow{\text{Selección}} \xrightarrow{\text{Cruce}} \xrightarrow{\text{Mutación}} P_{t+1}$$

Límite de campo medio ($N \rightarrow \infty$)

Comportamiento asintótico

Cuando el tamaño de población N tiende a infinito, la medida empírica μ_t^N **converge** (en probabilidad) a una medida determinista μ_t que satisface:

$$\mu_{t+1} = K(\mu_t)$$


Theorem (Champagnat, Ferrière & Méléard, 2006)

En el límite $N \rightarrow \infty$, la evolución de la población sigue la ecuación:

$$\frac{\partial}{\partial t} \mu_t = \underbrace{\text{Selección}[\mu_t]}_{\text{replicador}} + \underbrace{\text{Cruce}[\mu_t]}_{\text{mezcla}} + \underbrace{\text{Mutación}[\mu_t]}_{\text{difusión}}$$

¿Qué significa el límite de campo medio?

- El **ruido** estocástico desaparece en el límite
- La dinámica se vuelve **determinista**
- Se obtiene una **ecuación de evolución** (no lineal, por la selección)



Analogía física: Un gas con muchas moléculas tiene un comportamiento promedio (presión, temperatura) determinista, aunque las moléculas individuales se muevan aleatoriamente.

Convergencia débil de μ_t

Condiciones suficientes

- Fitness **continuo** y acotado
- Mutación **gaussiana** $\Rightarrow$ soporte completo en $\mathbb{R}^n$
- $\alpha \geq 0$ en BLX- α (típicamente $\alpha = 0.5$)
- Elitismo (opcional, acelera la convergencia)

Theorem (Convergencia débil)

Bajo estas condiciones, μ_t converge débilmente a una distribución límite μ_∞ :

$$\int f(\mathbf{x}) d\mu_t(\mathbf{x}) \xrightarrow{t \rightarrow \infty} \int f(\mathbf{x}) d\mu_\infty(\mathbf{x})$$

para toda función f continua y acotada.

Interpretación y el Teorema de Cerf

¿Qué significa convergencia débil?

La población no colapsa necesariamente a un solo punto, sino que su **distribución** tiende a una distribución límite.

Ejemplo

Si f vale 1 cerca del óptimo y 0 lejos:

$$\int f(\mathbf{x}) d\mu_t(\mathbf{x}) = \text{proporción de individuos cerca del óptimo} \rightarrow 1$$

Theorem (Cerf, 1998)

Bajo condiciones similares (mutación positiva, espacio compacto, fitness continuo):

$$\mathbb{P} \left(\lim_{t \rightarrow \infty} \|\mathbf{x}_{\text{mejor}}^{(t)} - \mathbf{x}^*\| = 0 \right) = 1$$

Convergencia casi segura (más fuerte que la débil).

Distribuciones continuas como límite

¿Por qué "distribuciones continuas"?


- El espacio de búsqueda $\mathbb{R}^n$ es continuo
- La mutación gaussiana produce **densidades continuas**
- μ_∞ suele ser una **distribución de Gibbs**:

$$\mu_\infty(d\mathbf{x}) \propto e^{F(\mathbf{x})/\tau} d\mathbf{x}$$

Concentración en el óptimo

- Fitness con único máximo global $\Rightarrow \mu_\infty = \delta_{\mathbf{x}^*}$ (masa de Dirac)
- Múltiples óptimos $\Rightarrow \mu_\infty$ es una **mezcla** de masas

Esquema del desarrollo



Limitaciones y desafíos abiertos

- Maldición de la dimensionalidad
 - El volumen del espacio crece exponencialmente con n
 - Se necesitan poblaciones muy grandes
- Selección del paso de mutación σ
 - Trade-off entre exploración y explotación
 - Estrategias adaptativas (autoadaptación)
- Convergencia a óptimos locales
 - Problemas multimodales
 - Técnicas de niching
- Análisis teórico más complejo que en caso binario
 - Espacio de estados no numerable
 - Operadores continuos vs. discretos

Comparación con otros métodos

Método	Espacio	Ventajas	Desventajas
AG binario	$\{0, 1\}^n$	Teoría madura	Mala precisión en continuo
AG real	$\mathbb{R}^n$	Natural para continuo	Análisis complejo
Recocido simulado	$\mathbb{R}^n$	Convergencia garantizada	Lento, sin población
Enjambre de partículas	$\mathbb{R}^n$	Paralelizable	Menos teoría de convergencia
Estrategias evolutivas	$\mathbb{R}^n$	Adaptación de parámetros	Complejidad de implementación

Nota: Los AGs reales son especialmente útiles cuando la función objetivo es continua pero no diferenciable, o cuando el espacio de búsqueda es de alta dimensión.

Conclusiones

- 1 Los AGs en espacios métricos generales son herramientas poderosas para optimización continua
- 2 Su análisis requiere cadenas de Markov en espacios continuos y teoría de medidas
- 3 El límite de campo medio y la convergencia débil proporcionan un marco riguroso
- 4 Quedan desafíos abiertos: alta dimensionalidad, adaptación de parámetros

Referencias clave

- Beyer, H.G. & Schwefel, H.P. (2002). *Evolution strategies – A comprehensive introduction. Natural Computing*
- Spall, J.C. (2003). *Introduction to stochastic search and optimization. Wiley*
- Chang, F. J. & Chen, L. (1998). *Real-Coded Genetic Algorithm for Rule-Based. Flood Control Reservoir Management*

Gracias por su atención